

World Model for Robot Learning: A Comprehensive Survey

<https://arxiv.org/html/2605.00080v1>

TL;DR: World Model for Robot Learning 不只是"预测未来的模块", 而是一种可以被内化为策略骨干、用作仿真器训练、或作为视频生成基础层的统一范式





WM in robot Vs. Video Generation Model

预测未来 + 这个预测能被机器人用来做决策

当前 Robot Policy (visuomotor/ VLA) 存在3个缺陷

- 1. **Long-horizon reasoning**: 只看当前观测出动作，无法规划多步后的后果 → 任务步骤一多就容易失败
- 2. **Temporal credit assignment**: 奖励延迟,纯端到端策略难以学到这种长程因果关系
- 3. **Robustness**: 遇到分布外扰动时缺乏"想一想会怎样"的能力，容易做出不可逆的错误动作



当前的policy是“当前观测->动作”的直接映射, 而不是“当前观测->预判未来->基于预判做动作”, WM就是为了解决这个问题，给policy加上“想象未来”的能力

WM 怎么帮？

- 1. World Model for Policy
- 2. World Model as Simulator
- 3. World Model for Robotic Video Generation




World Model for Policy

子节	范式	WM 与 Policy 关系	代表
3.2	Decoupled IDM	WM 先预测未来 → IDM 反推动作 (串联)	UniPi, VidMan
3.3	Single Backbone	同一 backbone 联合生成未来视觉 + 动作	UVA, VideoVLA
3.4	MoE/MoT Expert	多 expert 保留分工, 层间持续交互	Motus, DiT4DiT
3.5	Latent-Space WM	不做像素预测, 在表示空间构造 future target	VLA-JEPA, FLARE
3.6	Unified VLA	VLA 自身内化 predictive structure	DreamVLA, WorldVLA

从"外挂 WM 模块"逐步走向"WM 能力内生于 policy backbone"

(a). IDM




方法	未来预测方式	特点
UniPi (Du et al., 2023)	显式视频 rollout	最早的代表性工作之一
VidMan (Wen et al., 2024)	显式视频 rollout	视频生成 + IDM 分离
Vidar (Feng et al., 2025)	显式视频 rollout	—
Gen2Act (Bharadhwaj et al., 2025)	显式 human-video rollout	人类演示视频作为条件
VPP (Hu et al., 2025)	隐式预测特征	不生成像素, 生成 latent 预测特征
Video2Act (Jia et al., 2025b)	隐式预测特征	—
MimicVideo (Pai et al., 2025)	隐式视觉规划	—

优势：① 模块化 ② 可解释性强 ③ 可以利用大规模视频预训练

缺点：① 两阶段训练，不是端到端优化，WM 不知道"什么样的预测对 IDM 最有用" ② 推理时开销大

(b). Single World Model Backbone



不再把"世界模型"和"策略"分成两个模型，而是让一个统一 backbone 同时学"未来会怎样"和"我该如何做"

(b) Single-Backbone-Style

为什么视频 backbone 适合做控制？

文中认为视频生成 backbone 在预训练时已学到三类对控制有价值的先验：

- 1.运动连续性: 动作轨迹平滑，避免突变
- 2.时间因果性:当前动作决定未来状态
- 3.近似物理动力学:隐式理解物体交互


对控制的价值

方法	核心特点
UVA	联合 video-action latent space; 推理时可通过轻量 decoder 绕过显式视频生成
UWA	视频和动作在同一 transformer 里扩散; 用 modality-specific timesteps 区分模态; 可边缘化视觉分支
VideoVLA / VideoPolicy	直接把预训练视频生成器改造成控制模型; 视频模型本身就是 backbone
Cosmos Policy	收紧视觉预测与动作控制的距离; 视觉分支更像隐藏推理流
DreamZero	未来视觉当作 latent predictive process; 推理时只取动作输出
UD-VLA	统一去噪过程
GigaWorld-Policy	大规模统一世界模型策略

发展趋势：视觉分支越来越不像"必须输出的视频结果"，而更像"指导动作的隐藏推理流"。重点不是生成更长更清晰的视频，而是让视频世界建模更深地内化进控制本身。



(c). MoE/MoT 混合专家策略



(c) MoT-Style

核心思想:

- 1.高层形式: $(\mathbf{h}_{\ell+1}^v, \mathbf{h}_{\ell+1}^a) = \mathcal{F}_{\ell}^{\text{mix}}(\mathbf{h}_{\ell}^v, \mathbf{h}_{\ell}^a; o_t, l),$
- 2.交互方式: joint attention / cross-attention / shared-attention fusion
- 3.视频分支从"必须输出的视频"转变为 *predictive latent process* (hidden states 指导动作分支)

动机 -> 为什么不完全共享参数?

差异维度	视频预测	动作生成
时间频率	较稠密的连续时序变化	高频、精确、低延迟信号
表示尺度	高维视觉 token / latent	低维控制命令
优化目标	时空一致性	可执行性和控制精度

full parameter sharing is not always optimal

代表方法(3 类)

第一类：并行 expert coupling

方法	特点
GE-Act	预训练 video diffusion backbone + 轻量 action branch; deep cross-attention 注入视频 latent

第二类：Mixture-of-Transformers 式深交互


方法	特点
Motus	understanding + video generation + action expert, 标准 MoT
LingBot-VA	video/action token 交织进共享 autoregressive 序列; dual-stream MoT + shared attention
BagelVLA	语言规划 + 视觉预测 + 动作生成放入同一执行循环
DiT4DiT	用视频分支中间去噪特征指导动作预测
Fast-WAM	收益更多来自训练时视频协同训练, 而非推理时显式想象

第三类：Latent-space expertization

方法	特点
LDA-1B	DINO latent space 视觉预测; 视觉/动作 expert 通过 shared self-attention 耦合
FRAPPE	学习 future-aware latent representations; 与视觉基础模型做 latent 对齐



(d). Latent-Space WM



(b) Latent World Modeling Policy


动机:

显式视频预测的问题	Latent-space 的优势
计算开销大 (要解码像素)	避免显式生成解码的开销
信息冗余 (背景纹理等控制无关细节)	只提取对动作有用的未来信息
像素级重建不等于对控制有帮助	直接学"对控制有用的未来结构"

代表方法:

方法	核心做法	关键词
FLARE	action denoising network 的 hidden feature 对齐 future observation 的 latent embedding	Future Latent Repr. Alignment
VLA-JEPA	Leakage-free state prediction: 未来帧只产生 latent supervision target, 逼模型学习动作相关的状态转移	JEPA-style, leakage-free
JEPA-VLA	直接用 V-JEPA 2 的 predictive embeddings 做 VLA backbone, 而非额外加 future head	Predictive pretraining as backbone
WoG	直接预测对精确控制最有用的 compact future-oriented conditions	Compact control conditions
DIAL	在 VLM feature space 中用 latent visual foresight 做结构化 bottleneck, 解耦高层意图与低层动作	Intent-action decoupling

(e). Unified VLA Models



(a) Unified Vision-Language-Action Model

不依赖外部视频 WM，在 VLA backbone 内部内化 future-oriented predictive modeling

类型	纯 reactive VLA	Unified VLA
输出	直接出动作	动作 + 某种未来预测目标
内在结构	当前→动作的直映射	动作生成与内部预测目标联合训练

预测目标可以是:

直接预测未来图像帧/

预测未来的压缩表示/



预测未来的语义描述



World Model as Simulator

WM 直接充当交互式仿真环境，供 RL 训练和 policy 评估使用

(a). World Model for Reinforcement Learning



WM for Policy中 WM 提供预测/监督/先验来增强 policy；在这里 WM 直接替代真实环境，policy 在 WM 内部做 rollout、收集奖励、迭代优化


Frozen WM: WM 当作现成的 simulator 用。比如用大规模视频数据预训练好一个 video WM，然后 policy 在里面做 RL

Co-evolution (Dreamer 系列的经典范式)


- 循环：
1. Policy 在真实环境收集数据 → 更新 WM
 2. WM 生成 imagined rollouts → RL 更新 Policy
 3. 回到 1

World Model as Simulator → WM 直接充当交互式仿真环境，供 RL 训练和 policy 评估使用

(b). World Model for Evaluation



WM作为 safety evaluator / policy validator：在部署前或运行时，用 WM 模拟候选动作的后果，进行筛选和验证



(b) World Model for Validation

代表方法

方法	核心特点
WorldFomo	WM-based offline policy evaluation; 用世界模型估计 policy 效用
VLA-RST (Storr et al., 2025)	video reward 用于策略验证和反馈
WorldGym	探索 WM 能否完全替代真实环境进行评估
BISE (Wang et al., 2025)	通过 appearance yields 增强评估真实性
HEPA	基于 WM 的 policy competition / benchmark
GigaSim	WM-based simulation 用于大规模策略评估

当前瓶颈：WM 的 fidelity 直接决定评估可信度；低保真 WM 可能给出误导性评分

Benchmarks, Datasets, Results

3层Benchmark

层级	评测问题	代表 Benchmark
Open-loop 预测质量	生成的未来是否忠实于 action command?	RBench, EWMBench, DreamGen Bench, EVA-Bench
Closed-loop 任务效用	预测放进交互决策循环后是否仍有用?	WorldArena, WorldEval, WorldGym, World-in-World
物理一致性诊断	生成的 rollout 是否 physically grounded 和 operationally executable?	WorldSimBench, WoW-World-Eval, WM-ABench

Datasets

数据集	特点
DROID (Khazatsky et al., 2024)	多 embodiment、多场景、大规模 real robot
Bridge V2	多任务操作、language conditioned
RoboSet (Bharadhwaj et al., 2023)	multi-embodiment 操作
CALVIN (Mees et al., 2022)	long-horizon language-conditioned benchmark
Galaxea Open World Dataset	cross-embodiment 大规模
Humanoid ZeroDay	人形机器人数据
DROID-Manip 2.1	多机型操作增强版
RoboCasa (Nasiriany et al., 2024)	模拟 + 真实混合; kitchen 长时程
TWOWI (2025)	大规模人类+机器人视频混合

Group	Method	Spatial	Object	Goal	Long	Avg
Decoupled	UniPi (Du et al., 2023)	–	–	–	0.0	–
	MimicVideo (Pai et al., 2025)	94.2	96.8	90.6	94.0	93.9
	Say-Dream-ACT (Gu et al., 2026)	99.4	99.2	98.6	95.4	98.1
Single-backbone	UVA (Li et al., 2025c)	–	–	–	90.0	–
	VideoPolicy (Liang et al., 2025a)	–	–	–	94.0	–
	Cosmos Policy (Kim et al., 2026)	98.1	100.0	98.2	97.6	98.5
	UD-VLA (Chen et al., 2026b)	94.1	95.7	91.2	89.6	92.7
MoE / MoT	Motus (Bi et al., 2025)	96.8	99.8	96.6	97.6	97.7
	LingBot-VA (Li et al., 2026b)	98.5	99.6	97.2	98.5	98.5
Unified VLA	RynnVLA-002 (Cen et al., 2025)	99.0	99.8	96.4	94.4	97.4
	DreamVLA (Zhang et al., 2025e)	97.5	94.0	89.5	89.5	92.6
	UniVLA (Bu et al., 2025b)	96.5	96.8	95.6	92.0	95.2
	Unified VLA (Wang et al., 2025)	95.4	98.8	93.6	94.0	95.5
	CoWVLA (Yang et al., 2026a)	97.2	97.8	94.6	92.8	95.6
	F1 (Lv et al., 2025)	98.2	97.8	95.4	91.3	95.7
	TriVLA (Liu et al., 2025d)	91.2	93.8	89.8	73.2	87.0
Latent-space WM	VLA-JEPA (Sun et al., 2026)	96.2	99.6	97.2	95.8	97.2
	JEPA-VLA (Miao et al., 2026)	97.2	98.0	95.6	94.8	96.4

Methods are grouped by the manner in which world modeling is incorporated into policy learning, rather than by publication year alone.
Avg denotes the average success rate over the four LIBERO suites when directly reported by the original paper. “–” indicates that the corresponding suite-level result was not directly reported under the standard Spatial/Object/Goal/Long protocol.

各范式之间差距已不大，说明 integration style 不是唯一决定因素

Long 列仍是多数方法的最低分:误差累积 + 长时程 credit assignment 仍是结构性难点



Benchmarks, Datasets, Results

3层Benchmark

层级	评测问题	代表 Benchmark
Open-loop 预测质量	生成的未来是否忠实于 action command?	RBench, EWMBench, DreamGen Bench, EVA-Bench
Closed-loop 任务效用	预测放进交互决策循环后是否仍有用?	WorldArena, WorldEval, WorldGym, World-in-World
物理一致性诊断	生成的 rollout 是否 physically grounded 和 operationally executable?	WorldSimBench, WoW-World-Eval, WM-ABench

Datasets

数据集	特点
DROID (Khazatsky et al., 2024)	多 embodiment、多场景、大规模 real robot
Bridge V2	多任务操作、language conditioned
RoboSet (Bharadhwaj et al., 2023)	multi-embodiment 操作
CALVIN (Mees et al., 2022)	long-horizon language-conditioned benchmark
Galaxea Open World Dataset	cross-embodiment 大规模
Humanoid ZeroDay	人形机器人数据
DROID-Manip 2.1	多机型操作增强版
RoboCasa (Nasiriany et al., 2024)	模拟 + 真实混合; kitchen 长时程
TWOWI (2025)	大规模人类+机器人视频混合

Results

Group	Method	Spatial	Object	Goal	Long	Avg
Decoupled	UniPi (Du et al., 2023)	–	–	–	0.0	–
	MimicVideo (Pai et al., 2025)	94.2	96.8	90.6	94.0	93.9
	Say-Dream-ACT (Gu et al., 2026)	99.4	99.2	98.6	95.4	98.1
Single-backbone	UVA (Li et al., 2025c)	–	–	–	90.0	–
	VideoPolicy (Liang et al., 2025a)	–	–	–	94.0	–
	Cosmos Policy (Kim et al., 2026)	98.1	100.0	98.2	97.6	98.5
	UD-VLA (Chen et al., 2026b)	94.1	95.7	91.2	89.6	92.7
MoE / MoT	Motus (Bi et al., 2025)	96.8	99.8	96.6	97.6	97.7
	LingBot-VA (Li et al., 2026b)	98.5	99.6	97.2	98.5	98.5
Unified VLA	RynnVLA-002 (Cen et al., 2025)	99.0	99.8	96.4	94.4	97.4
	DreamVLA (Zhang et al., 2025e)	97.5	94.0	89.5	89.5	92.6
	UniVLA (Bu et al., 2025b)	96.5	96.8	95.6	92.0	95.2
	Unified VLA (Wang et al., 2025)	95.4	98.8	93.6	94.0	95.5
	CoWVLA (Yang et al., 2026a)	97.2	97.8	94.6	92.8	95.6
	F1 (Lv et al., 2025)	98.2	97.8	95.4	91.3	95.7
	TriVLA (Liu et al., 2025d)	91.2	93.8	89.8	73.2	87.0
Latent-space WM	VLA-JEPA (Sun et al., 2026)	96.2	99.6	97.2	95.8	97.2
	JEPA-VLA (Miao et al., 2026)	97.2	98.0	95.6	94.8	96.4

Methods are grouped by the manner in which world modeling is incorporated into policy learning, rather than by publication year alone.

Avg denotes the average success rate over the four LIBERO suites when directly reported by the original paper. “–” indicates that the corresponding suite-level result was not directly reported under the standard Spatial/Object/Goal/Long protocol.

各范式之间差距已不大，说明 integration style 不是唯一决定因素

Long 列仍是多数方法的最低分:误差累积 + 长时程 credit assignment 仍是结构性难点



Presentation title

Name | Role



Credits

Challenges & Future Directions

因果条件缺口

效率瓶颈

